

Lectura de labios en tiempo real para español rioplatense: destilación causal de Auto-AVSR con corrección mediante un LM

Federico Gutman
fgutman@udesa.edu.ar

Mateo Bramer
mbramer@udesa.edu.ar

Santiago Bunge
sbunge@udesa.edu.ar

Martin Bianchi
mbianchi@udesa.edu.ar

Joaquín Szterensus
jszterensus@udesa.edu.ar

Ingeniería en Inteligencia Artificial, Universidad de San Andrés

Resumen

El reconocimiento visual del habla (*Visual Speech Recognition*, VSR), o lectura de labios automática, transcribe lo que una persona dice a partir únicamente del video de su rostro, sin audio. El estado del arte se concentra casi exclusivamente en inglés y en modelos no causales pensados para transcripción *offline*. Proponemos un sistema de VSR para **español rioplatense** que funcione en **tiempo real**: partimos de un modelo *teacher* grande (Auto-AVSR), lo adaptamos al español y lo **destilamos** a un *student* causal y liviano que solo observa cuadros pasados, sumando un modelo de lenguaje (LM) local que corrige el texto especulativo. Nuestra pregunta de investigación es cuánto se degrada la precisión —medida en *Word Error Rate* (WER)— al recorrer ese camino de comprensión y adaptación de dominio. Este documento describe la idea, el estado del arte y los planes de implementación y evaluación; no reporta resultados propios.

1. Introducción y motivación

El reconocimiento visual del habla (VSR) consiste en transcribir a texto lo que un hablante dice usando solo la información visual del movimiento de sus labios, sin recurrir al audio (Assael et al., 2016; Ma et al., 2022). Es una tarea intrínsecamente difícil: muchos fonemas son visualmente ambiguos y comparten la misma configuración labial (*vismas*, como *p*, *b* y *m*), por lo que el modelo debe apoyarse fuertemente en el contexto lingüístico, y existe gran variabilidad entre hablantes, iluminaciones y poses.

El problema es interesante por varias razones. Primero, por **accesibilidad**: un lector de labios automático puede asistir a personas con discapacidad auditiva, con afonía o problemas del habla, pacientes post-ACV o con enfermedades neurodegenerativas. Segundo, porque el VSR es robusto justamente donde el audio falla —entornos ruidosos, micrófonos a distancia o conversaciones donde preservar

la **privacidad** del audio es deseable. Tercero, por un **vacío concreto**: prácticamente todo el progreso reciente se ha dado en inglés (Ma et al., 2023), mientras que el español está sub-representado y el **español rioplatense** —con su léxico, voseo y fonética propios— prácticamente ausente de los recursos públicos.

Nuestra propuesta combina dos contribuciones. Como **proyecto de investigación**, estudiamos cuánto se degrada un modelo **causal** (que solo ve cuadros pasados, requisito para tiempo real) y **destilado** (comprimido) al adaptarlo al rioplatense. Como **proyecto de ingeniería**, construimos un sistema *end-to-end* con transcripción en pantalla en tiempo real, donde un LM local corrige sobre la marcha el texto crudo del modelo visual.

2. Trabajo relacionado

Arquitecturas y datasets en inglés. El VSR moderno arranca con modelos *end-to-end* de aprendizaje profundo como LipNet (Assael et al., 2016) y los trabajos sobre los corpus *Lip Reading Sentences in the Wild* (LRS2/LRS3) (Chung et al., 2017; Afouras et al., 2018), que establecieron el reconocimiento de oraciones continuas en condiciones realistas. Ma et al. (2022) mostraron arquitecturas de VSR de alto rendimiento para múltiples idiomas. **Auto-AVSR** (Ma et al., 2023) es el referente actual: escala el entrenamiento audiovisual usando etiquetas generadas automáticamente y alcanza WER muy bajos en inglés; es el modelo *teacher* del que partimos.

VSR en español. El recurso central para español es **LIP-RTVE** (Gimeno-Gómez and Martínez-Hinarejos, 2022), un modelo pre-entrenado con un corpus audiovisual extraído de programas de la televisión española (RTVE), sobre el que se han estudiado los factores que influyen en la lectura de labios continua en español (Gimeno-Gómez and Martínez-Hinarejos, 2025). Estos trabajos están en

español **peninsular**; ninguno aborda el rioplatense, que es la brecha que buscamos cubrir.

Para ello vamos a construir un corpus propio recolectado de YouTube, seleccionando videos de noticieros, entrevistas y programas de opinión argentinos donde el hablante aparece de frente a la cámara con la región labial claramente visible. Las transcripciones se obtienen automáticamente con Whisper y se segmentan en clips de entre 2 y 10 segundos usando los *timestamps* de Whisper como puntos de corte naturales. El corpus resultante contiene vocabulario, construcciones de voseo y modismos propios del español rioplatense que no están representados en LIP-RTVE ni en los corpus usados para pre-entrenar Auto-AVSR.

Prototipos aplicados y en tiempo real. La lectura de labios se ha aplicado a la rehabilitación de pacientes con discapacidad vocal (Innocente et al., 2025) y a herramientas de asistencia como Visual Voice (vis, 2025) y LIP-TRAC (Saravana). El precedente más cercano a nuestro objetivo de ingeniería es Chaplin (Virparhar, 2025), un sistema de VSR **local y en tiempo real** construido sobre Auto-AVSR; a diferencia de nuestra propuesta, funciona en inglés y no incorpora un corrector basado en LM.

Técnicas que utilizamos. Nuestro modelo se entrena con *Connectionist Temporal Classification* (CTC) (Graves et al., 2006), que permite alinear secuencias de video y texto sin alineación explícita. El *backbone* temporal es un **Conformer** (Gulati et al., 2020), que combina convoluciones y atención; nosotros usamos una variante **causal**. Para comprimir el *teacher* en un *student* pequeño aplicamos **destilación de conocimiento** (Hinton et al., 2015). Finalmente, la detección y recorte de la región labial se hace con MediaPipe (Lugaresi et al., 2019), y la corrección de texto se delega a un LM.

3. Implementación propuesta

El sistema procesa video en línea, en *chunks* cortos, para nunca esperar a que el hablante termine de hablar (Figura 1).

Preprocesamiento. Una cámara captura el rostro a 25 fps (RGB). MediaPipe (Lugaresi et al., 2019) detecta *landmarks* faciales; se recorta la región labial a 96×96 px, se pasa a escala de grises y se normaliza. Los cuadros se agrupan en *chunks* de 8 (≈ 320 ms).




Figura 1: Pipeline *end-to-end* en tiempo real. El extractor visual corre por cada *chunk*; el corrector LM trabaja en un hilo separado para no bloquear el flujo.

Modelo VSR. Cada *chunk* alimenta un **ResNet-3D** (extractor visual, congelado) seguido de un **Conformer causal** (el *student*) y una cabeza **CTC** con vocabulario en español. La arquitectura es estrictamente causal: solo usa cuadros pasados, garantizando latencia acotada. El *student* se obtiene por destilación del *teacher* Auto-AVSR.

Estrategia de entrenamiento. (1) Tomamos el modelo VSR de Gimeno-Gómez and Martínez-Hinarejos (2025) como punto de partida, un sistema visual puro ya adaptado al español sobre LIP-RTVE. (2) Lo afinamos con nuestro corpus rioplatense recolectado de YouTube; este modelo fine-tuneado constituye el *teacher*. (3) Destilamos (Hinton et al., 2015) ese *teacher* en un *student* causal y liviano apto para inferencia en tiempo real.

Modelo de lenguaje rioplatense. Durante la decodificación, el CTC genera hipótesis candidatas que son rescoradas por un **LM de caracteres** fine-tuneado en español rioplatense, siguiendo la arquitectura de Gimeno-Gómez and Martínez-Hinarejos (2025). El LM es un Transformer de 16 capas entrenado sobre el corpus de texto extraído de los videos de YouTube, y actúa dentro del beam search asignando mayor probabilidad a construcciones rioplatenses como *vos tenés* o *che* frente a sus equivalentes peninsulares. La puntuación combinada es:

$$S = \lambda S_{\text{CTC}} + (1 - \lambda) S_{\text{attn}} + \beta S_{\text{LM}}$$

donde $\lambda = 0,1$ y $\beta = 0,4$ siguiendo Gimeno-Gómez and Martínez-Hinarejos (2025).

4. Plan de evaluación

La métrica principal es el **Word Error Rate** (WER), porcentaje de palabras mal reconocidas. Diseñamos una **ablación** que aísla el efecto de cada etapa del *pipeline*:

- **Baseline**: Auto-AVSR *zero-shot* en español $\rightarrow \text{WER}_{\text{baseline}}$.
- **Teacher**: Auto-AVSR afinado en español $\rightarrow \text{WER}_{\text{teacher}}$.
- **Student**: *student* causal sin destilación $\rightarrow \text{WER}_{\text{student}}$.
- **Student+KD**: *student* con destilación $\rightarrow \text{WER}_{\text{distillation}}$.
- **+LM**: lo anterior con el corrector LM $\rightarrow \text{WER}_{\text{lm}}$.

Además medimos **eficiencia** (número de parámetros, *real-time factor* y latencia por *chunk*) para verificar la viabilidad en tiempo real, y **generalización** evaluando tanto en el *test split* en español como en un **conjunto de test rioplatense propio**. La pregunta de investigación que guía todo es: *¿cuánto se degrada un modelo causal destilado de Auto-AVSR al adaptarlo al español rioplatense?* No se esperan resultados propios para esta entrega.

References

2025. Visual voice: An AI powered lip reading technology. IEEE Xplore, document 11158201. <https://ieeexplore.ieee.org/document/11158201>; autores y venue por confirmar.
- Triantafyllos Afouras, Joon Son Chung, and Andrew Zisserman. 2018. **LRS3-TED: A large-scale dataset for visual speech recognition**. *arXiv preprint arXiv:1809.00496*.
- Yannis M. Assael, Brendan Shillingford, Shimon Whiteson, and Nando de Freitas. 2016. **LipNet: End-to-end sentence-level lipreading**. *arXiv preprint arXiv:1611.01599*.
- Joon Son Chung, Andrew Senior, Oriol Vinyals, and Andrew Zisserman. 2017. **Lip reading sentences in the wild**. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*.
- David Gimeno-Gómez and Carlos-D. Martínez-Hinarejos. 2022. **LIP-RTVE: An audiovisual database for continuous Spanish in the wild**. In *Proceedings of the Thirteenth Language Resources and Evaluation Conference (LREC)*, pages 2750–2758, Marseille, France.
- David Gimeno-Gómez and Carlos-D. Martínez-Hinarejos. 2025. **Evaluation of end-to-end continuous Spanish lipreading in different data conditions**. *Language Resources and Evaluation*.
- Alex Graves, Santiago Fernández, Faustino Gomez, and Jürgen Schmidhuber. 2006. **Connectionist temporal classification: Labelling unsegmented sequence data with recurrent neural networks**. In *Proceedings of the 23rd International Conference on Machine Learning (ICML)*, pages 369–376.
- Anmol Gulati, James Qin, Chung-Cheng Chiu, Niki Parmar, Yu Zhang, Jiahui Yu, Wei Han, Shibo Wang, Zhengdong Zhang, Yonghui Wu, and Ruoming Pang. 2020. **Conformer: Convolution-augmented transformer for speech recognition**. In *Interspeech 2020*, pages 5036–5040.
- Geoffrey Hinton, Oriol Vinyals, and Jeff Dean. 2015. **Distilling the knowledge in a neural network**. *arXiv preprint arXiv:1503.02531*.
- Chiara Innocente, Matteo Boemio, Gianmarco Lorenzetti, Ilaria Pulito, Diego Romagnoli, Valeria Saponaro, Giorgia Marullo, Luca Ulrich, and Enrico Vezzetti. 2025. **Deep learning-based lip-reading for vocal impaired patient rehabilitation**. *Computer Modeling in Engineering & Sciences (CMES)*, 143(2):1355–1379.
- Camillo Lugaresi, Jiuqiang Tang, Hadon Nash, Chris McClanahan, Esha Uboweja, Michael Hays, Fan Zhang, Chuo-Ling Chang, Ming Guang Yong, Juhyun Lee, Wan-Teh Chang, Wei Hua, Manfred Georg, and Matthias Grundmann. 2019. **MediaPipe: A framework for building perception pipelines**. *Preprint*, arXiv:1906.08172.
- Pingchuan Ma, Alexandros Haliassos, Adriana Fernandez-Lopez, Honglie Chen, Stavros Petridis, and Maja Pantic. 2023. **Auto-AVSR: Audio-visual speech recognition with automatic labels**. In *ICASSP 2023 – IEEE International Conference on Acoustics, Speech and Signal Processing*.
- Pingchuan Ma, Stavros Petridis, and Maja Pantic. 2022. **Visual speech recognition for multiple languages in the wild**. *Nature Machine Intelligence*, 4:930–939.
- Monish Saravana. LIP-TRAC: Real-time lipreading for enhanced communication. <https://liptrac.com/>. Sitio del proyecto.
- Aman Virparhar. 2025. Chaplin: A real-time visual speech recognition system. <https://github.com/amanvirparhar/chaplin>. Proyecto de software de código abierto.